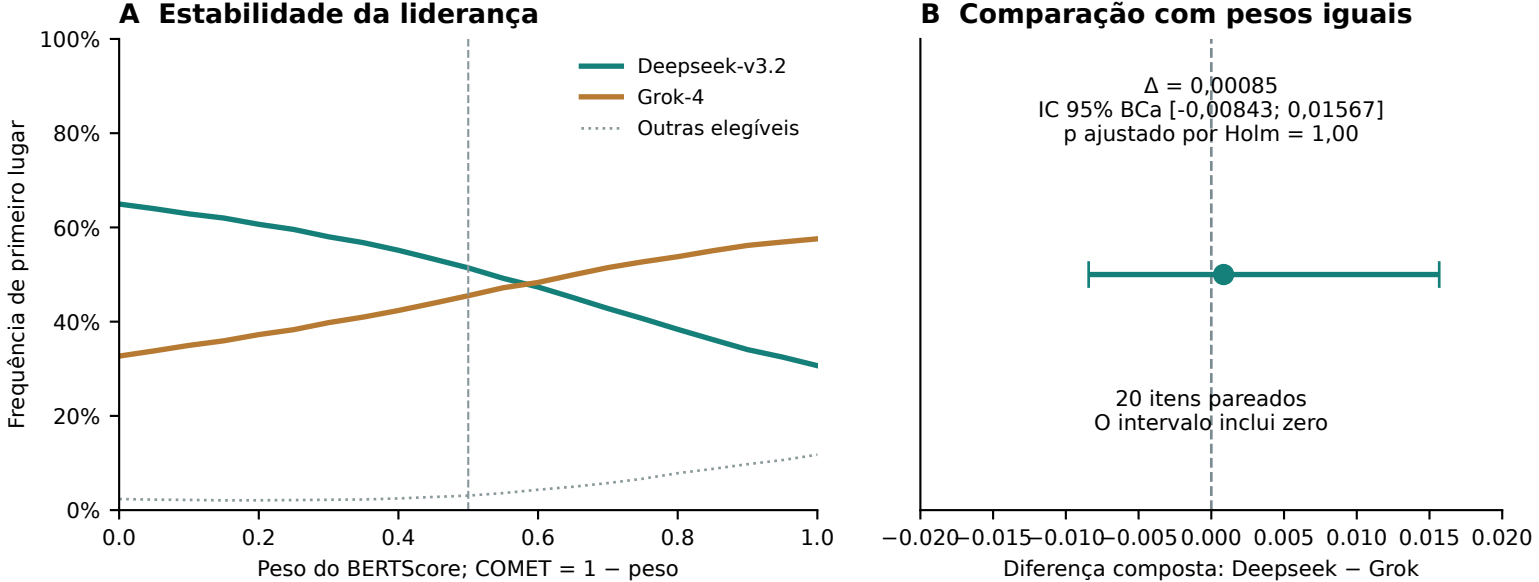
A Estabilidade da liderança
Deepseek-v3.2
Grok-4
Outras elegíveis
Frequência de primeiro lugar
100%
80%
60%
40%
20%
0%
0.0
0.2
0.4
0.6
0.8
1.0
Peso do BERTScore; COMET = 1 − peso
B Comparação com pesos iguais
Δ = 0,00085
IC 95% BCa [-0,00843; 0,01567]
p ajustado por Holm = 1,00
20 itens pareados
O intervalo inclui zero
−0.020
−0.015
−0.010
−0.005
0.000
0.005
0.010
0.015
0.020
Diferença composta: Deepseek − Grok